

编译技术



胡春明 hucm@buaa.edu.cn 2019.9-2019.12

> Excellence in BUAA SEI



编译过程



编译过程是指将<mark>高级语言程序翻译为等价的目标程</mark> 序的过程。

习惯上是将编译过程划分为5个基本阶段:

语法分析 语义分析、生成中间代码 代码优化 生成目标程序





第七章 源程序的中间形式

- ・波兰表示
- N 元表示
- 抽象机代码





波兰表示





一般编译程序都生成中间代码,然后再生成目标代码,主要优点是可移植(与具体目标程序无关), 且易于目标代码优化。有多种中间代码形式:

波兰表示 N - 元组表示 抽象机代码

波兰表示

由波兰逻辑学家 J.Lukasiewicz 提出

• 前缀表示: <操作符><操作数序列>

• 后缀表示:<操作数序列><操作符>

前缀表达: (波兰表达) + 35

后缀表达: (逆波兰表达) 35+



Compiler

7.1 波兰表示

一般编译程序都生成中间代码,然后再生成目标代码,主要优点是可移植(与具体目标程序无关), 且易于目标代码优化。有多种中间代码形式:

波兰表示 N - 元组表示 抽象机代码

波兰表示

算术表达式: F*3.1416*R*(H+R)

转换成波兰表示: F3.1416*R*HR+*

赋值语句: A := F * 3.1416 * R * (H + R)

波兰表示: AF3.1416 * R * HR + * :=





波兰表示

从语法树的角度看"波兰表示"

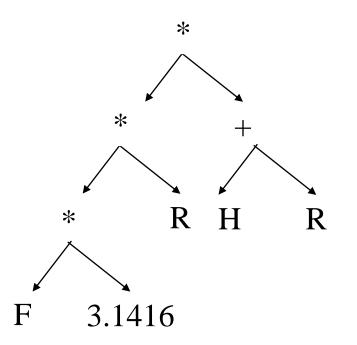
算术表达式:

F*3.1416*R*(H+R)

 $E::=E+T\mid T$

 $T ::= T*F \mid F$

F ::= (E) | i



前序遍历

中序遍历

后序遍历





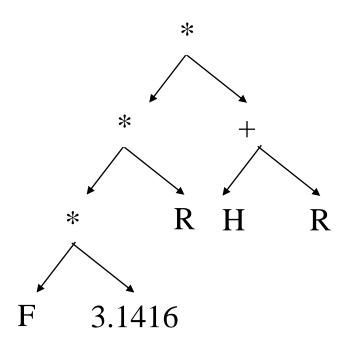
波兰表示

从语法树的角度看"波兰表示"

算术表达式:

F*3.1416*R*(H+R)

E::= E+T | T T ::= T*F | F F ::= (E) | i



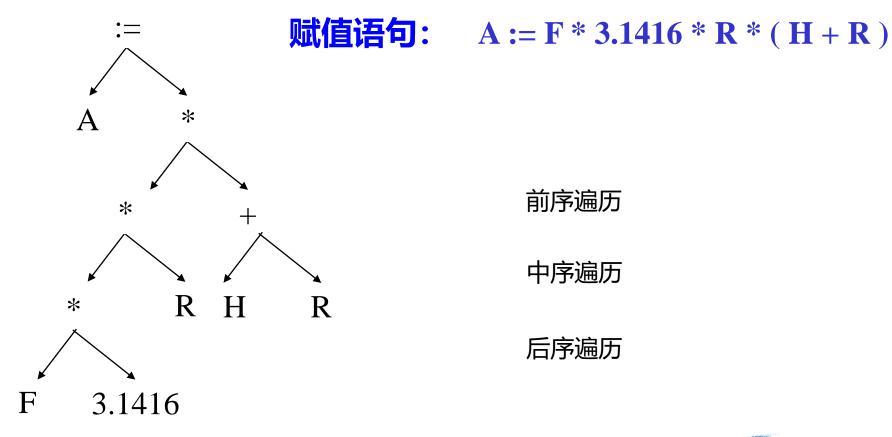
逆波兰表示: F3.1416*R*HR+*





波兰表示

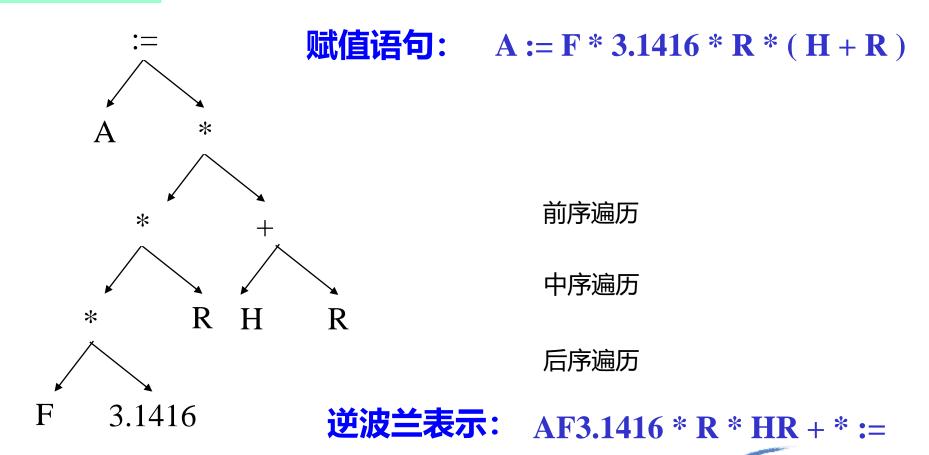
从语法树的角度看"波兰表示"





波兰表示

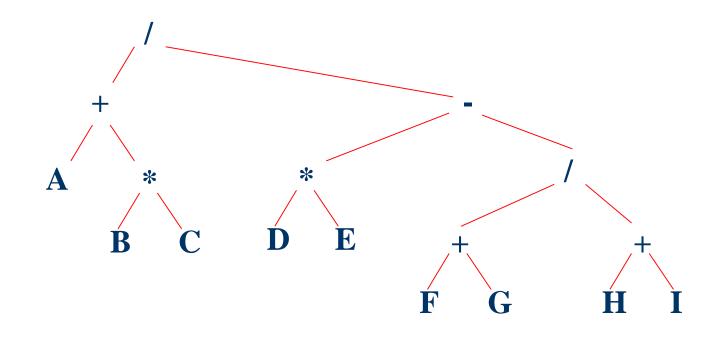
从语法树的角度看"波兰表示"



Excellence in



例: (A+B*C)/(D*E-(F+G)/(H+I))



前序遍历(根左右): /+A*BC-*DE/+FG+HI

后序遍历(左右根): ABC*+DE*FG+HI+/-/

中序遍历(左根右): A+B*C/D*E-F+G/H+I

(波兰表达)

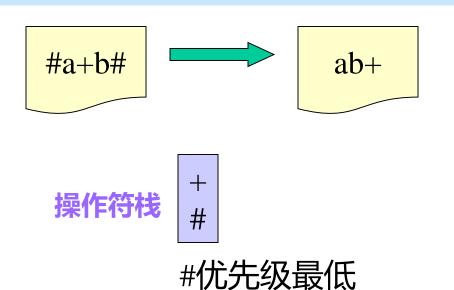
(逆波兰表达)



北京航空航天大学计算机学院



构造一个算法,生成"波兰表示"



算法:

设一个操作符栈;当读到操作数时,立即输出该操作数, 当扫描到操作符时,与栈顶操作符比较优先级,若栈顶操作 符优先级高于栈外,则输出该栈顶操作符,反之,则栈外操 作符入栈。





转换算法

```
波兰表示
              算术表达式:
                                   F * 3.1416 * R * (H + R)
 操作符栈
                                                 输出
                         输入
                    F * 3.1416 * R * (H + R)
                                                   F
                      * 3.1416 * R * ( H + R )
                                                   F
  *
                       3.1416 * R * (H + R)
 *
                             * R * (H + R)
                                                  F 3.1416
  *
                              R * (H + R)
                                                  F 3.1416 *
  *
                                 * (H + R)
                                                  F 3.1416 * R
  *
                                                  F 3.1416 * R *
                                  (H+R)
  *(
                                    H + R)
                                                  F 3.1416 * R *
  *(
                                      +R)
                                                  F 3.1416 * R * H
                                        R)
                                                  F 3.1416 * R * H
                                                   F 3.1416 * R * HR
  *(
                                                   F 3.1416 * R * HR+
                                                   F 3.1416 * R * HR+*
```

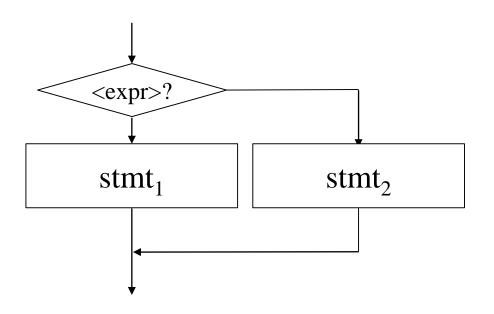
波兰表示: F3.1416 * R * HR + *





if 语句的波兰表示

if 语句 : if <expr> then <stmt₁> else <stmt₂>



 $\begin{array}{c|c} & \text{expr} \\ & \text{bz : lable 1} \\ & \text{stmt}_1 \\ & \text{: label 1} \\ & \text{stmt}_2 \\ & \text{: label 2} \end{array}$

label₁



label₂



if 语句的波兰表示

label label 2

if 语句 : if <expr> then <stmt₁> else <stmt₂>

波兰表示为 : <expr><label₁>BZ<stmt₁><label₂>BR<stmt₂>

expr

bz:lable1

stmt₁

:label1

br:lable1

 $stmt_2$

:label2

BZ: 二目操作符

若<expr>的计算结果为0(false),

则产生一个到<label₁>的转移

BR: 一目操作符

产生一个到< label₂>的转移





波兰表示为 : <expr><label₁>BZ<stmt₁><label₂>BR<stmt₂>

由if语句的波兰表示可生成如下的目标程序框架:

<expr>
BZ label₁
<stmt₁>
BR label₂
label₁: <stmt₂>

label₂:

其他语言结构也很容易将其翻译成波兰表示,

使用波兰表示的问题: 优化不是十分方便。





其他语言结构也很容易将其翻译成波兰表示,使用波兰表示的问题: 优化不是十分方便。

波兰表达式 隐含了 "栈操作" 能否将波兰表达式拆成一组 "原子操作" ?





N元表示





7.2 N - 元表示

在该表示中,每条指令由n个域组成,通常第一个域表示操作符,其余为操作数。

常用的n元表示是: 三元式 四元式

三元式

操作符

左操作数

右操作数

表达式的三元式:

$$\mathbf{w} * \mathbf{x} + (\mathbf{y} + \mathbf{z})$$



- (2) +, y, z
- (3) +, (1), (2)

第三个三元 式中的操作数(1)

- (2)表示第(1)和第
- (2)条三元式的计 算结果。



条件语句的三元式:

- (1) -, x, y
- (2) BMZ, (1), (5)
- (3) :=, z, x
- (4) BR, (7)
- (5) +, y, 1
- (6) :=, z, (5)
- **(7)**

•

其中:

BMZ: 是二元操作符,测试第二

个域的值,若≤0,则按

第3个域的地址转移,

若>0,则顺序执行。

BR: 一元操作符,按第3个域

作无条件转移。

Excellence in BUAA SEI



使用三元式不便于代码优化,因为优化要删除一些三元式,或对某些三元式的位置要进行变更,由于三元式的结果(表示为编号),可以是某个三元式的操作数,随着三元式位置的变更也将作相应的修改,很费事。

间接三元式:

为了便于在三元式上作优化处理,可使用间接三元式

三元式的执行次序用另一张表表示,这样在优化时,三元式可以不变,而仅仅改变其执行顺序表。



Compiler

例: A:=B+C*D/E

F:=C*D

用间接三元式表示为:

操作

- 1. (1)
- 2. (2)
- 3. (3)
- 4. (4)
- **5.** (1)
- **6.** (**5**)

三元式

- (1) *, C, D
- (2) / , (1), E
- (3) + , B, (2)
- (4) := , A, (3)
- (5) := , F, (1)



操作符 操作数1 操作数2 结果

结果: 通常是由编译引入的临时变量, 可由编译程序

分配一个寄存器或主存单元。

例:
$$(A+B)*(C+D)-E$$



式中T1, T2, T3, T4 为临时变量,由四 元式优化比较方便





操作符 操作数1 操作数2 结果

```
int a;
int b;
int c;
int d;

a = b + c + d;
b = a * a + b * b;
```





操作符 操作数1 操作数2 结果

```
int x;
int y;
int z;
if (x < y)
   z = x;
else
   z = y;
z = z * z;
```

```
__t0 = x < y;
IfZ __t0 Goto __L0;
z = x;
Goto __L1;
__L0:
z = y;
__L1:
z = z * z;
```





操作符 操作数1 操作数2 结果

```
int x;
int y;
while (x < y) {
    x = x * 2;
}
y = x;</pre>
```

```
_L0:
_t0 = x < y;
IfZ _t0 Goto _L1;
x = x * 2;
Goto _L0;
_L1:
_y = x;
```





操作符 操作数1 操作数2 结果

```
void main() {
  int x, y;
  int m2 = x * x + y * y;

while (m2 > 5) {
    m2 = m2 - x;
  }
}
```

```
main:
  BeginFunc 24;
   t0 = x * x;
   t1 = y * y;
  m2 = t0 + t1;
L0:
   t2 = 5 < m2;
   IfZ t2 Goto L1;
  m2 = m2 - x;
   Goto L0;
L1:
   EndFunc;
```





操作符 操作数1 操作数2 结果

```
void SimpleFn(int z) {
    int x, y;
    x = x * y * z;
}

void main() {
    SimpleFunction(137);
}
```

```
SimpleFn:
   BeginFunc 16;
   t0 = x * y;
   t1 = t0 * z;
   x = t1;
   EndFunc;
main:
   BeginFunc 4;
    t0 = 137;
   PushParam t0;
   LCall SimpleFn;
   PopParams 4;
   EndFunc;
```

Source: Stanford CS143 (2012)

Excellence in BUAA SEI



抽象语法树





7.3 抽象语法树

中间代码的图结构表示

抽象语法树:

用树型图的方式表示中间代码 操作数出现在叶节点上,操作符出现在中间结点

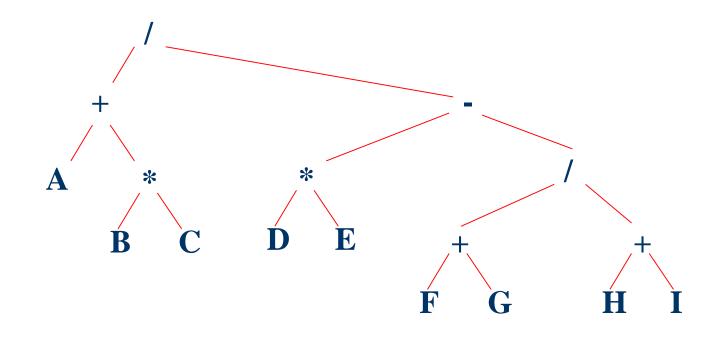
DAG图:

Directed Acyclic Graphs 有向无环图 语法树的一种归约表达方式





例: (A+B*C)/(D*E-(F+G)/(H+I))



前序遍历(根左右): /+A*BC-*DE/+FG+HI

后序遍历(左右根): ABC*+DE*FG+HI+/-/

中序遍历(左根右): A+B*C/D*E-F+G/H+I

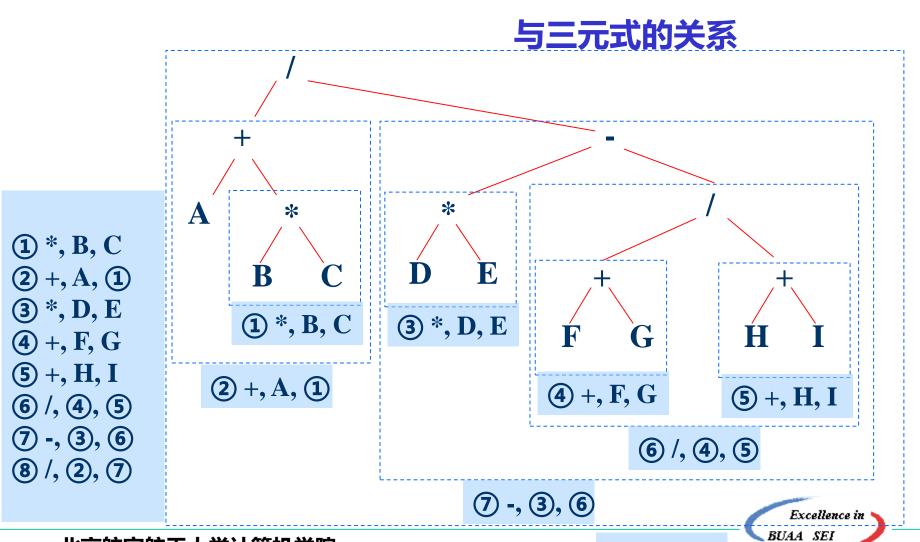
(波兰表达)

(逆波兰表达)





例: (A+B*C)/(D*E-(F+G)/(H+I))

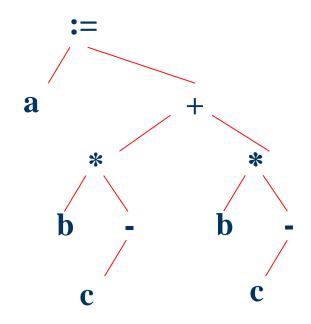


北京航空航天大学计算机学院

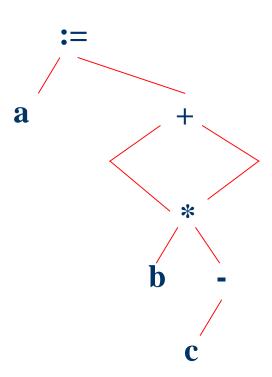
8/, 2, 7



例: 赋值语句: $a:=b^*(-c) + b^*(-c)$



抽象语法树 (其中有重复部分)

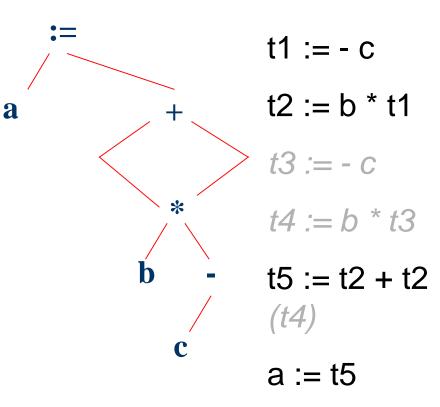


有向无环图 (DAG)



例: 赋值语句: a:=b*(-c) + b*(-c) 对应的TAC

抽象语法树 (其中有重复部分)



有向无环图 (DAG)

Excellence in S BUAA SEI



例子: P-Code的抽象机





7.3 抽象机代码

许多pascal编译系统生成的中间代码是一种称为P-code的抽象代码,P-code的"P"即"Pseudo"

抽象机:

寄存器 保存程序指令的存储器 堆栈式数据及操作存储



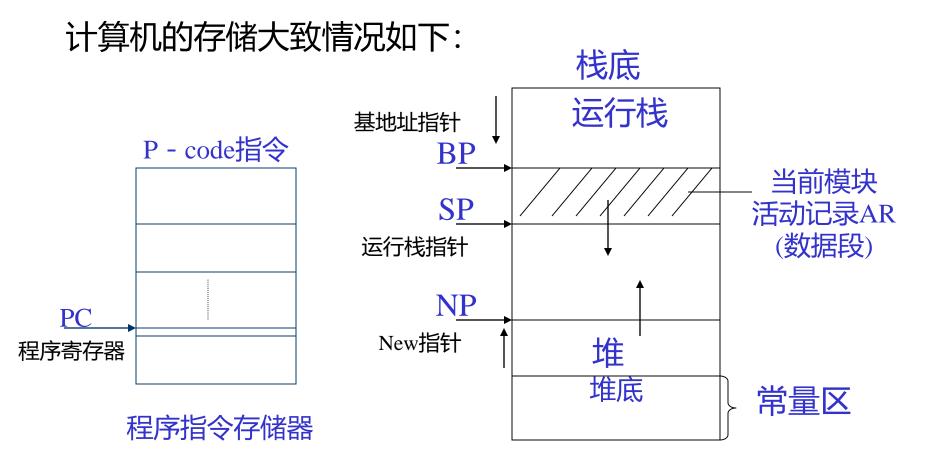


寄存器有:

- 1. PC 程序计数器
- 2. NP New指针,指向"堆"的顶部。"堆"用来存放由New 生成的动态数据。
- 3. SP 运行栈指针,存放所有可按源程序的数据声明直接 寻址的数据。
- 4. BP 基地址指针,即指向当前活动记录的起始位置指针。
- 5. 其他, (如MP-栈标志指针, EP-极限栈指针等)



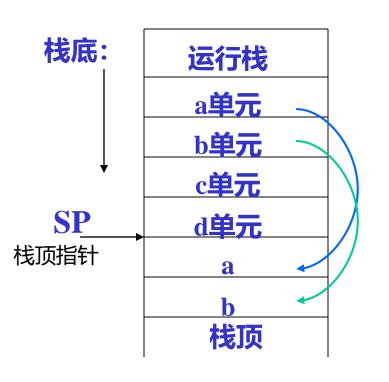








运行P - code的抽象机没有专门的运算器或 累加器,所有的运算(操作)都在运行栈的栈顶进 行,如要进行d:=(a+b)*c的运算,生成P - code序 列为:



取 a	LOD a
取b	LOD b
+	ADD
其 Cc	LOD c
*	MUL
送d	STO d

P - code实际上是波兰表示形式的中间代码





P-Code指令集 (p184, 10.2)

- 40 ABI 取整数绝对值
- 41 ABR 取实数绝对值
- 28 ADI 整数加
- 29 ADR 实数加
- 53 DVI 整数除
- 54 DVR 实数除
- 42 NOT 布尔 "非"
- 43 AND 布尔"与"
- 26 CHK Q 检查越界

- 15 CSP Q 调用标准过程
- 12 CUPP, Q 调用用户过程
- 19 GEQ P, Q 大于等于
- 20 GRT P, Q 大于
- 48 INN 判定集合成员
- 48 INT **取交**集
- 4 LDA P, Q 加载地址
- 7 LDC P, Q 加载常量
- 23 UJP Q 无条件跳转
- 24 FJP Q 为假时条件跳转

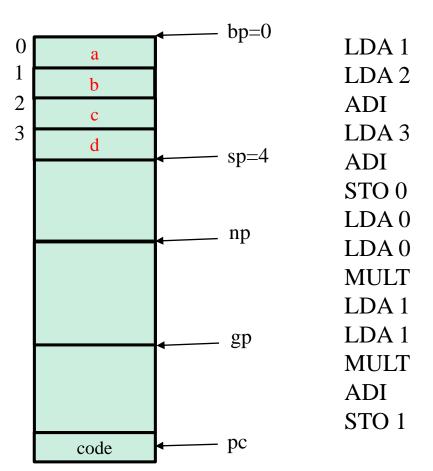


- 40 ABI 取整数绝对值
- 41 ABR 取实数绝对值
- 28 ADI 整数加
- 29 ADR 实数加
- 53 DVI 整数除
- 54 DVR **实数除**
- 42 NOT 布尔 "非"
- 43 AND 布尔"与"
- 26 CHK Q 检查越界

- 15 CSP O 调用标准过程
- 12 CUP P, Q 调用用户过程
- 19 GEQ P, Q 大于等于
- 20 GRT P, O 大于
- 48 INN 判定集合成员
- 48 INT **取交**集
- 4 LDA P, O 加载地址
- 7 LDC P, Q 加载常量
- 23 UJP Q 无条件跳转
- 24 F.IP O 为假时条件跳转

$$a = b + c + d;$$

 $b = a * a + b * b;$





- 40 ABI 取整数绝对值
- 41 ABR 取实数绝对值
- 28 ADI 整数加
- 29 ADR **实数加**
- 53 DVI 整数除
- 54 DVR 实数除
- 42 NOT 布尔"非" 43 AND 布尔"与"
- 26 CHK Q 检查越界

- 12 CUP P, O 调用用户过程
- 19 GEQ P, Q 大于等于
- 20 GRT P, Q 大于
- 48 INN 判定集合成员
- 4 LDA P, O 加载地址
- 7 LDC P, Q 加载常量
- 23 UJP Q 无条件跳转
- 24 FJP O 为假时条件跳转

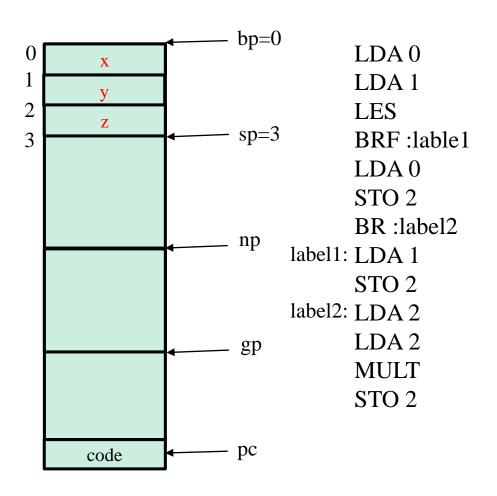
if
$$(x < y)$$

$$z = x;$$

else

$$z = y;$$

$$z = z * z;$$





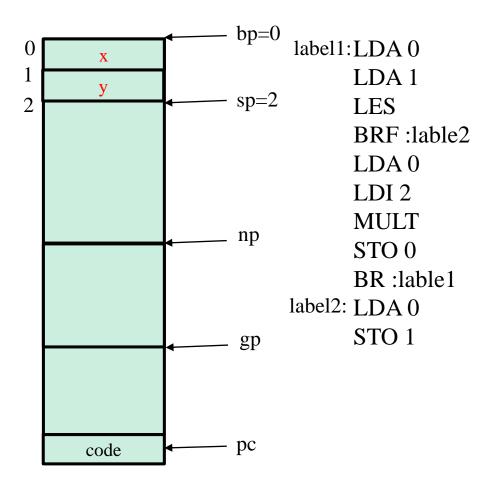
- 40 ABI 取整数绝对值
- 41 ABR 取实数绝对值
- 28 ADI 整数加
- 29 ADR **实**数加
- 53 DVI 整数除
- 54 DVR 实数除
- 42 NOT 布尔"非" 43 AND 布尔"与"
- 26 CHK Q 检查越界

- 12 CUP P, O 调用用户过程
- 19 GEQ P, Q 大于等于
- 20 GRT P, Q 大于

- 4 LDA P, O 加载地址
- 7 LDC P, Q 加载常量
- 23 UJP Q 无条件跳转
- 24 FJP O 为假时条件跳转

while
$$(x < y)$$
 {
 $x = x * 2;$

$$y = x$$
;



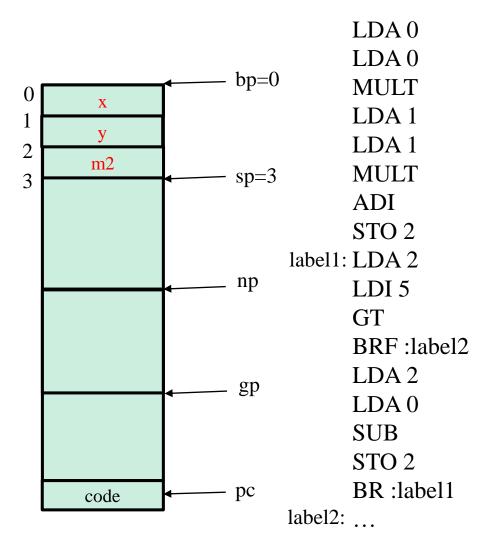


```
40 ABI 取整数绝对值
41 ABR 取实数绝对值
28 ADI 整数加
29 ADR 实数加
53 DVI 整数除
54 DVR 实数除
42 NOT 布尔"非"
43 AND 布尔"与"
26 CHK Q 检查越界
```

```
15 CSP Q 调用标准过程
12 CUP P, Q 调用用户过程
19 GEQ P, Q 大于等于
20 GRT P, Q 大于
48 INN 判定集合成员
48 INT 取交集
4 LDA P, Q 加载地址
7 LDC P, Q 加载常量
23 UJP Q 无条件跳转
24 FJP Q 为假时条件跳转
```

```
void main() {
  int x, y;
  int m2 = x * x + y * y;

while (m2 > 5) {
    m2 = m2 - x;
  }
}
```



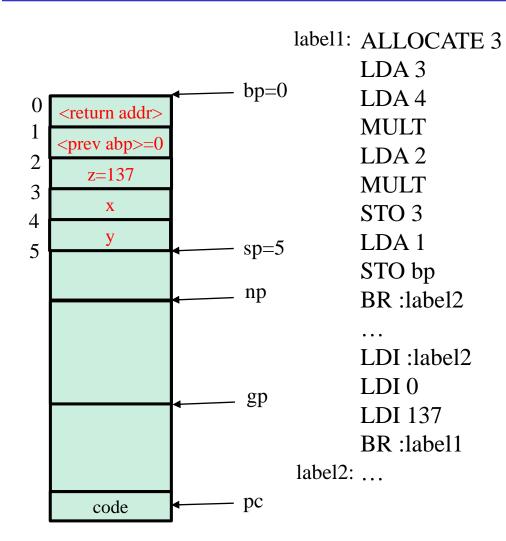


```
40 ABI 取整数绝对值
41 ABR 取实数绝对值
28 ADI 整数加
29 ADR 实数加
53 DVI 整数除
54 DVR 实数除
42 NOT 布尔 "非"
43 AND 布尔 "与"
26 CHK Q 检查越界

15 CSP Q 调用标准过程
12 CUP P, Q 调用用户过程
19 GEQ P, Q 大于等于
20 GRT P, Q 大于
48 INN 判定集合成员
48 INT 取交集
4 LDA P, Q 加载地址
7 LDC P, Q 加载常量
23 UJP Q 无条件跳转
24 FJP Q 为假时条件跳转
```

```
void SimpleFn(int z) {
    int x, y;
    x = x * y * z;
}

void main() {
    SimpleFunction(137);
}
```







编译程序生成P - code指令程序后,我们可以用一个解释执行程序 (interpreter) 来解释执行P - code, 当然也可以把P - code再变成某一机器的目标代码。

显然,生成抽象机P - code的编译程序是很容易移植的。





错误处理





第八章 错误处理

- 概述
- ・错误分类
- 错误的诊察和报告
- 错误处理技术





8.1 概述

1. 必备功能之一

正确的源程序: 通过编译生成目标代码

错误的源程序:通过编译发现并指出错误

2. 错误处理能力

- (1) 诊察错误的能力
- (2) 报错及时准确
- (3) 一次编译找出错误的多少
- (4) 错误的改正能力
- (5) 遏止重复的错误信息的能力



Compiler

8.2 错误分类

从编译角度,将错误分为两类:语法错误和语义错误

语法错误: 源程序在语法上不合乎文法

如:

$$A[I, J := B + * C$$

语义错误主要包括:程序不符合语义规则或

超越具体计算机系统的限制





语义规则:

- ・标识符先说明后引用
- ・标识符引用要符合作用域规定
- ·过程调用时实参与形参要一致
- ・参与运算的操作数类型一致
- ・下标变量下标不能越界

超越系统限制:

- ・数据溢出错误
- · 符号表、静态存储分配数据区溢出
- · 动态存储分配数据区溢出





8.3 错误的诊察和报告

错误诊察:

 违反语法和语义规则以及超过编译系统限制的错误。 编译程序: 语法和语义分析时 (语义分析要借助符号表)

2. 下标越界, 计算结果溢出以及动态存储数据区溢出。

目标程序: 目标程序运行时

对此,编译程序要生成相应的目标程序作检查

和进行处理





错误报告:

1. 出错位置: 即源程序中出现错误的位置

实现: 行号计数器 line_no

单词序号计数器 char_no

- 一旦诊察出错误,当时的计数器内容就是出错位置
- 2. 出错性质:

可直接显示文字信息

可给出错误编码





3. 报告错误的两种方式:

(1) 分析完以后再报告(显示或者打印)

编译程序可设一个保存错误信息的数据区(可用记录型数组),将语法语义分析所诊察到的错误 送数据区保存,待源程序分析完以后,显示或打印错误信息。

例:
$$A[x, y := B + *C]$$

源程序行号	错误序号	错误性质
X X	6	缺少"]"
X X	10	表达式语法错误





(2) 边分析边报告

可以在分析一行源程序时若发现有错,立即输出该行源程序,并在其下输出错误信息。

有时候报错不一定十分准确 (位置和性质),需进一步分析 例 begin

......

i := 1 step 1 until n do

end





8.4 错误处理技术

发现错误后,在报告错误的同时还要对错误进行处理,以方便编译能进行下去。目前有两种处理办法:

1. 错误改正: 指编译诊察出错误以后, 根据文法进

行错误改正。

如: A[i,j] := B + *C

但不是总能做到, $\mathbf{u}_{A}:=\mathbf{B}\cdot\mathbf{C}*\mathbf{D}+\mathbf{E}$

2. 错误局部化处理: 指当编译程序发现错误后,尽可能把错误的影响限制在一个局部的范围,避免错误扩散和影响

程序其他部分的分析。

要正确地改正错误



(1) 一般原则

当诊察到错误以后,就暂停对后面符号的 分析,跳过错误所在的语法成分然后继续往下分析。

词法分析: 发现不合法字符, 显示错误, 并跳

过该标识符(单词)继续往下分析。

语法语义分析: 跳过所在的语法成分(短语或语

句),一般是跳到语句右界符, 然后从新语句继续往下分析。





(2) 错误局部化处理的实现 (递归下降分析法)

cx: 全局变量,存放错误信息。

·用递归下降分析时,如果发现错误,便将有关错误信息(字符串或者编号)送CX,然后转出错误处理程序;

·出错程序先打印或显示出错位置以及出错信息,然后跳出一段源程序,直到跳到语句的右界符(如: end)或正在分析的语法成分的合法后继符号为止,然后再往下分析。



Compiler 例:条件语句分析: if then <stmt>[else< stmt>];

有如下分析程序:

```
procedure if_stmt;
begin
                           /*读下个单词符号*/
  nextsym;
                           /*调用布尔表达式处理程序*/
   B;
  if not class='then' then
    begin
                           /*错误性质送cx*/
      cx:='缺then'
                           /*调用出错处理程序*/
      error;
    end;
   else
    begin
       nextsym;
       statement
    end;
   if class='else'then
    begin
       nextsym;
        statement;
    end
end if_stmt;
```



局部化处理的出错程序为:

```
procedure error;
begin
write(源程序行号, 序号, cx)
repeat
nextsym;
until class = ';' or class = 'end' or class = 'else'
end error;
```



real x, 3a, a, bcd, 2fg;





(3) 提高错误局部化程度的方法

设 S1: 合法后继符号集 (某语法成分的后继符号)

S2: 停止符号集 (跳读必须停止的符号集)

进入某语法成分的分析程序时:

S1:= 合法后继符号

S2:= 停止符号





当发现错误时: error(S₁,S₂)

```
procedure error(S1,S2)
  begin
  write(line_no, char_no, cx);
  repeat
      nextsym
  until(class in S1 or class in S2);
  end
```

```
if<B> then <stmt>[else< stmt >]
若<B>有错,则可跳到then,
若<stmt>有错,则可跳到else。
```





3.目标程序运行时错误检测与处理.

下标变量下标值越界 计算结果溢出 动态存储分配数据区溢出

·在编译时生成检测该类错误的代码。

对于这类错误,要正确的报告出错误位置很难,因为目标程序与源程序之间难以建立位置上的对应关系

一般处理办法:

当目标程序运行检测到这类错误时,就调用异常处理程序,打印错误信息和运行现场(寄存器和存储器中的值)等,然后停止程序运行。



小结:本节+上一节:为代码生成做"需求分析"

- ·数据结构在内存里是如何表示的
- · 函数在内存中是如何表示的
- ·他们在内存中如何放置,如何管理
- . 中间代码如何表示

-- 让编译器聪明一些: 错误处理!

作业: p144 1,2,3,4





编译实验: 错误处理





目标和要求:

- 针对常见的错误分类编写错误处理程序,考核学生 对错误处理方法的掌握情况,培养学生编写错误处 理程序的能力
- 学生需分析编译过程的每个阶段可能出现的错误,
 学完"第8章 错误处理"后,对各阶段的错误进行错误局部化处理,并进行补充和完善,按要求输出错误信息
- 作业提交至教学平台,用5个测试程序进行测试,并 进行相似性检查。根据输出结果与预期结果一致部 分所占的比例给分。





评测:

- 自动评测
- 错误类别码按下表中的定义输出, 行号从1开始计数
- 约定1: 输入的被编译源文件统一命名为testfile.txt
- 约定2:错误信息输出的结果文件统一命名为error.txt
- 约定3: 结果文件中每行按如下方式组织

错误所在的行号 错误的类别码

(行号与类别码之间只有一个空格) (类别码严格按照表格中的小写英文字母)





错误类型及编码:

错误类型	错误类别码
非法符号或不符合词法	a
名字重定义	b
未定义的名字	c
函数参数个数不匹配	d
函数参数类型不匹配	e
条件判断中出现不合法的类型	f
无返回值的函数存在不匹配的return语句	g
有返回值的函数缺少return语句或存在不匹配的return语句	h
数组元素的下标只能是整型表达式	i
不能改变常量的值	j
应为分号	k
应为右小括号')'	1
应为右中括号']'	m
do-while语句中缺少while	n
常量定义中=后面只能是整型或字符型常量	0



测试样例:

```
const int const1 = 1, const2 = -100;
  const char const3 = ''?';
  int change1;
  char change3;
  int gets1(int var1,int var2){
6
     change1 = var1 + var2
      return (change1);
  void main(){
      change1 = 10;
10
11 printf("Hello World");
     printf(gets1(10, 20));
12
13 }
```

```
2 a
6 k
```





注意事项:

- 本次作业的每个测试程序各包含1-3个错误,均来自前述表格;按报出错误占应报错误的比例得分
- 表中未包含的错误,需自行设计,本作业考核不涉及
- 完成本次作业时,不需要输出词法分析和语法分析作业要求输出的内容
- 本次考核之外,发现错误时最好直接输出描述信息, 而不是仅给出错误类别码
- 输出到 error.txt 中的错误信息,每行末尾都需要加一 个换行符 \n





谢谢!

